

Orange Executive Brief

面向 AI Agent 的信任海关

Nimclea Orange(TM) | First Public Preview

权限效果: NONE | 可供运行时消费: false | 完整白皮书:

orange-white-paper.zh-CN.pdf

Agentic AI 系统正在从文本生成走向真实行动: 修改代码、调用工具、部署系统、与客户沟通、处理数据, 以及管理基础设施。

Orange 为拟议动作与外部后果之间的边界定义一种确定性的行动权限架构。

Agent 可以自由思考, 但不能自由越权。

宪法规则

Prompt 不是权限。
Agent 的声称不是证据。
UNKNOWN 不是许可。
先阻断, 再变更现实。
没有观察到不等于观察到了不存在。

宪法先前技术边界

Orange 不是用于塑造模型行为的宪法。Orange 不声称发明 Constitutional AI 或模型对齐。

Orange 治理的是不同层级: 在受保护的外部动作发生之前, 建立经人类确认的确定性权限。

模型原则 != 执行权限
已经对齐的行为 != 改变现实的许可

Orange 做什么

1. 编译权限	2. 为受保护动作设闸	3. 验证闭环
人类意图通过确定性、可审阅规则形成可见的 Authority Draft。只有明确的人类确认、冻结、哈希、版本化与激活, 才能形成可执行 Authority Contract。Orange 不把正式权限解释委托给 LLM。	在受保护变更发生之前, Orange 要求 Action Event、确定性 Predicate 闭环、Authority Gateway 判断, 以及绑定到 Protected Adapter 的有效 Scoped Execution Token。	动作获准执行后, 独立观察支持结构化 Issue Card 或 Release Log。覆盖边界与盲区必须保持显式。

为什么重要

流量检查
!=
行动权限核验

变更现实后的审计
!=
变更现实前的控制

身份、最小权限、沙箱、日志与普通网关仍然必要。Orange 继续追问:

在 Agent 改变现实之前, 哪些条件必须为真?

第一扇受保护的门

第一个受限 Demo Profile 有意保持狭窄:

/sandbox/** = allow
/prod/** = deny

它用于展示: 已注册受保护路径可以放行经授权动作; 在副作用发生前阻断未经授权的变更; 拒绝无效 Token; 用独立观察核对 Agent 的声称; 重放受限输入; 并披露剩余盲区。

当前公共证明边界

本 Brief 与配套白皮书记载公共架构、定义词汇、证明义务、成熟度区分, 以及受限 Demo 验收画像。

它们**不认证**生产就绪、普遍不可旁路性、完整云端覆盖、完整 Child-Agent 治理、外部证明, 或已经完成的 Receipt 信任生态。

纸面架构 != 运行时证明
已注册路径执法 != 全部路径不可旁路